

УДК 004 Хаустова И.В., Аникина О.В.

Хаустова И.В.

студент группы ПИмд-2205а

Тольяттинский государственный университет

(г. Тольятти, Россия)

Научный руководитель:

Аникина О.В.

канд. тех. наук, доцент кафедры прикладной математики и информатики

Тольяттинский государственный университет

(г. Тольятти, Россия)

ИСПОЛЬЗОВАНИЕ ПОЛНОСТЬЮ ГОМОМОРФНОГО ШИФРОВАНИЯ ДЛЯ ЗАЩИТЫ ДАННЫХ В МАШИННОМ ОБУЧЕНИИ В ОБЛАКЕ

***Аннотация:** в работе рассматривается проблема недостаточной защищённости конфиденциальных данных, используемых банком для машинного обучения в облаке. Для решения проблемы было проанализировано использование полностью гомоморфного шифрования в машинном обучении и аппроксимирование сигмоидной функции. Была решена задача кредитного скоринга с обеспечением полной безопасности данных, для чего с помощью библиотеки TenSEAL данные на клиенте были зашифрованы с помощью схемы CKKS и загружены на сервер, где на зашифрованных данных была обучена модель логистической регрессии, продемонстрировавшая такую же точность, как и модель, обученная на незашифрованных данных.*

***Ключевые слова:** полностью гомоморфное шифрование, CKKS, логистическая регрессия, полиномиальная аппроксимация, конфиденциальное машинное обучение.*

Введение

В данной работе рассматривается ситуация, в которой банк, использующий в своей деятельности машинное обучение, столкнулся с

нехваткой вычислительной мощности, поэтому было принято решение арендовать для этих целей облачный сервер. Однако так как данные передаются на сторонний сервер, то возникает проблема обеспечения безопасности данных, используемых для машинного обучения, актуальность решения которой заключается в том, что уязвимости в самом облаке, возможности несанкционированного доступа или даже неправильная настройка доступа к облаку могут привести к угрозам информационной безопасности, например, утечке данных, что снизит уровень доверия клиентов, а также приведёт к репутационным потерям и штрафам за нарушение правил информационной безопасности.

Современные тенденции в области обеспечения безопасности машинного обучения включают в себя широкий класс методов для обеспечения безопасности и конфиденциальности данных. Например, многосторонние вычисления позволяют нескольким участникам совместно выполнять вычисления над общими данными без раскрытия этих данных друг другу [20], а концепция дифференциальной приватности позволяет уменьшить связь данных с пользователями за счёт создания ограничений [9].

Такие методы достаточно практичны и могут быть легко интегрированы в существующие системы машинного обучения, но при их использовании содержание данных в том или ином виде всё равно раскрывается перед сервером, и предотвратить это можно только с использованием полностью гомоморфного шифрования, которое позволяет выполнять вычисления, в частности, сложение и умножение, над зашифрованными данными без их расшифровки, что обеспечивает наивысший уровень безопасности [1], так как содержание данных никогда не раскрывается. Такое свойство гомоморфного шифрования, из-за которого его также называют «святым Граалем криптографии» [14], делает его применение лучшим выбором для защиты данных в машинном обучении.

Целью данной работы является разработка модели машинного обучения на зашифрованных данных на примере решения задачи кредитного скоринга,

а новизна работы заключается в реализации клиент-серверного сценария использования библиотеки TenSEAL путём передачи на сервер уже зашифрованных на клиенте данных.

Для того, чтобы показать, насколько эффективно обучение модели логистической регрессии на зашифрованных данных, предлагается предварительно обучить эту же модель, но не на зашифрованных данных.

Для решения поставленной цели необходимо решить следующие задачи:

- Проанализировать источники и литературу по применению полностью гомоморфного шифрования для машинного обучения, в частности, по решению задачи аппроксимации сигмоидной функции.
- Найти и подготовить данные для решения задачи кредитного скоринга.
- Определить схему и параметры шифрования, после чего зашифровать подготовленные данные.
- Разработать механизм выгрузки зашифрованных данных и их отправку на сервер.
- Обучить модель логистической регрессии на зашифрованных и незашифрованных данных.
- Проанализировать результаты обучения модели на зашифрованных данных.

1 Анализ источников и литературы по применению полностью гомоморфного шифрования для машинного обучения

Большинство работ [3, 13, 15, 17, 18], посвященных использованию полностью гомоморфного шифрования для машинного обучения, описывают только шифрование на фазе вывода работы нейронной сети, и не касаются этапа обучения. Например, работа [15] посвящена аддитивно-гомоморфному шифрованию с интерактивным протоколом, в результате чего вывод небольшой нейронной сети занял всего 10 секунд, в то время как в следующей работе [18] для набора данных MNIST вывод занял уже 30 мс.

Предположительно, небольшое внимание к обучению на зашифрованных данных обусловлено тем, что оно занимает слишком много времени, однако уже в 2019 году в работе [16] с помощью библиотеки HELib была обучена нейронная сеть на основе стохастического градиентного спуска (SGD), что продемонстрировало эффективность обучения на зашифрованных данных, а также авторы предложили несколько методов для улучшения обучения, например, анализ сети, выбор подходящего представления данных и оптимизация упаковки данных в зашифрованных текстах.

В работе [12] была реализована логистическая регрессия и аппроксимированная функция логистической регрессии с помощью схемы CKKS и с использованием Microsoft SEAL. Процент правильных прогнозов совпал для обучения на открытых и зашифрованных данных, однако после шифрования размер входного набора данных увеличился в 272.5 раз, а время обработки данных увеличилось примерно в 4865 раз.

Также не все работы используют существующие схемы полностью гомоморфного шифрования. В работе [19] был представлен вариант бесшумной схемы гомоморфного шифрования на основе матрицы (MORE), которая требует достаточно небольших вычислительных затрат, однако обеспечивает меньшую безопасность по сравнению со стандартными схемами, так как основывается на линейных функциях и существует возможность определения секретного ключа, имея доступ к достаточно большому количеству пар зашифрованных и незашифрованных значений.

Для дальнейшего анализа существующих работ по теме исследования, важно отметить, что так как при использовании полностью гомоморфного шифрования над зашифрованными данными возможны только операции сложения и умножения, то с помощью них должны быть представлены все вычисляемые функции. В то время как в машинном обучении требуются неполиномиальные функции, в частности, логистической регрессии, применяемой для решения поставленной задачи кредитного скоринга, необходима сигмоидная функция:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (1)$$

Как видно из формулы (1), сигмоида не может быть эффективно представлена с помощью только сложения и умножения, и поэтому не может быть вычислена гомоморфно, поэтому разработка эффективного способа поддержки неполиномиальных функций является активной темой исследований в последние годы.

Самый первый способ поддержки неполиномиальных функций заключается в использовании полиномиальной замены, был самым первым решением проблемы поддержки неполиномиальных функций, и был представлен в 2016 году в работе [8], посвящённой CryptoNets, в которой авторы предложили замену сигмоиды квадратичным полиномом, который, однако, растёт экспоненциально и вызывает нестабильность во время обучения нейросети [4]. Как следствие, CryptoNets не может поддерживать более одного уровня активации.

Другой способ был представлен в 2018 году в работе [7], который заключается в предварительном вычислении дискретных выборок неполиномиальной функции активации и сохранении этих дискретных значений в справочной таблице. Во время гомоморфных вычислений программа выполняет поиск по таблице, однако низкие частоты дискретизации снижат точность вычислений с плавающей точкой и окажут прямое влияние на производительность нейронных сетей.

Однако более эффективный и часто используемый способ поддержки неполиномиальных функций заключается в аппроксимации неполиномиальных функций полиномами низкой степени. Использование низкой степени обусловлено тем, что схемы гомоморфного шифрования ограничивают количество операций умножения.

Представим наиболее используемые методы полиномиальной аппроксимации сигмоидной функции в виде таблицы 1, используя полиномы для первых четырёх подходов из работы [2], а для минимаксной

аппроксимации – из работы [6]. При этом рассмотрим только полиномы третьей степени, так как полиномы второй степени не обеспечивают достаточную точность [12], а более высокие степени ограничиваются количеством умножений в гомоморфном шифровании [4].

Для оценки качества аппроксимации используем среднюю квадратичную ошибку. В работе [2] значения MSE уже рассчитаны, в то время как для минимаксной аппроксимации её требуется рассчитать по формуле:

$$MSE(f, p) = \frac{1}{m} \cdot \sum_{i=1}^m (f(x_i) - p(x_i))^2 \quad (2)$$

Таблица 1 – Полиномиальные аппроксимации для сигмоидной функции

Метод	Полином	MSE
Численный метод [2] $x_i \sim U(-200, 200)$	$\sigma(x) = -1.378 \cdot 10^{-7} \cdot x^3 - 3.097 \cdot 10^{-7} \cdot x^2$ $+ 0.007042 \cdot x + 0.5127$	0.0328
Ряд Тейлора [2]	$\sigma(x) = -2.437 \cdot 10^{-8} \cdot x^3 - 2.054 \cdot 10^{-19} \cdot x^2$ $+ 0.003363 \cdot x + 0.5$	0.0634
Полиномы Чебышёва [2]	$\sigma(x) = -1.061 \cdot 10^{-7} \cdot x^3 - 2.141 \cdot 10^{-20} \cdot x^2$ $+ 0.006365 \cdot x + 0.5$	0.0340
Аппроксимация производной [2]	$\sigma(x) = -5.305 \cdot 10^{-8} \cdot x^3 + 0.004774 \cdot x + 0.5305$	0.0445
Минимаксная аппроксимация [6] $x \in [-5; 5]$	$\sigma(x) = -0.004 \cdot x^3 + 0.197 \cdot x + 0.5$	0.0114

Из таблицы 1 видно, что минимаксная аппроксимация сигмоидной функции показывает наименьшую среднюю квадратичную ошибку, но, чтобы убедиться в этом, построим графики аппроксимирующей и сигмоидной функций, как показано на рисунке 1.




Рис 1. Графики аппроксимирующей (минимаксная аппроксимация) и сигмоидной функций

Таким образом, в результате проведённого анализа, для решения задачи кредитного скоринга предлагается использовать аппроксимирующую функцию, полученную с помощью минимаксной аппроксимации, так как она наиболее точно аппроксимирует сигмоидную функцию.

Также следует отметить, что во всех рассмотренных работах процесс шифрования данных не выделяется на отдельный этап, то есть в рамках клиент-серверной архитектуры загрузка и шифрование данных происходит на сервере, а не на клиенте, что подвергает данные определённым угрозам информационной безопасности, и что предлагается решить в рамках данной работы путём разработки дополнительного функционала для библиотеки TenSEAL.

2 Разработка модели машинного обучения с использованием полностью гомоморфного шифрования

2.1 Решение задачи кредитного скоринга с помощью машинного обучения

Задача кредитного скоринга в банке заключается в оценке способности потенциального заёмщика выполнить свои кредитные обязательства — то есть, в определении вероятности того, что заёмщик своевременно будет

выплачивать кредит. Решение этой задачи помогает банку управлять рисками кредитования, минимизировать потери от невозврата кредитов и увеличить прибыль.

В настоящее время данная задача решается с помощью методов машинного обучения, и так как при её решении требуется классифицировать два взаимоисключающих класса (вернёт заёмщик кредит или не вернёт), то она относится к задачам бинарной классификации.

Одной из популярных моделей для решения таких задач является логистическая регрессия, которая моделирует вероятность принадлежности заёмщика к одному из двух классов, которые можно определить как «Надёжный заёмщик» и «Ненадёжный заёмщик». Логистическая регрессия предсказывает вероятность того, что заёмщик окажется надёжным, на основе набора входных переменных (например, возраст заёмщика, его доход, кредитная история, сумма кредита и т. д.).

Несмотря на существование более сложных и мощных алгоритмов машинного обучения, логистическая регрессия остаётся популярным выбором для решения задачи кредитного скоринга благодаря своей простоте и интерпретируемости и способности, что делает её идеальным первым шагом в построении более сложных моделей оценки кредитного риска.

Логистическую регрессию можно рассматривать как простую однослойную нейронную сеть, использующую сигмоидальную функцию активации (1).

Модель логистической регрессии вычисляет взвешенную сумму входных переменных (плюс смещение), и выводит вероятность результата:

$$\hat{p} = h_{\theta}(x) = \sigma(\theta^T x) \quad (3)$$

где h_{θ} – функция гипотезы с использованием параметров модели;

σ – логистическая функция (1);

θ^T – транспонированный вектор параметров модели.

При этом если предполагаемая вероятность больше 50 %, то модель предсказывает, что экземпляр принадлежит положительному классу «1»

(заёмщик вернёт кредит), а если меньше 50 %, то экземпляр принадлежит отрицательному классу «0» (заёмщик не вернёт кредит).

Так как решаемая задача кредитного скоринга относится к задачам бинарной классификации, то в качестве функции потери используется бинарная потеря кросс-энтропии, которая измеряет несоответствие между предсказанными вероятностями и истинными бинарными метками, что позволяет оценить, насколько хорошо модель предсказывает вероятность принадлежности к положительному классу.

$$L = \frac{1}{m} \cdot \sum_{i=1}^m [y^{(i)} \cdot \log(\hat{y}^{(i)}) + (1 - y^{(i)}) \cdot \log(1 - \hat{y}^{(i)})] \quad (4)$$

где m – количество экземпляров в наборе данных.

$y^{(i)}$ – фактическая метка для каждого экземпляра (0 или 1)

$\hat{y}^{(i)}$ – предсказанная вероятность принадлежности экземпляра положительному классу

В качестве оптимизатора логистической регрессии используется стохастический градиентный спуск, так как он требует меньше вычислений на итерацию, используя только один обучающий пример за раз при обновлении веса модели. Это делает его особенно подходящим для обучения на больших данных, где полный проход может быть очень затратным по времени.

Для обучения модели был выбран набор данных «Credit score classification», скачанный с Kaggle, который включает в себя практически полную информацию о заёмщике (28 столбцов), например, Annual_Income – годовой доход или Monthly_Inhand_Salary – ежемесячный доход. Также данные были очищены и нормализованы, так как используемая функция аппроксимации сигмоиды определена только на отрезке $[-5; 5]$, то и все данные, в том числе, числовые, были нормализованы в рамках заданного диапазона.

2.2 Полностью гомоморфное шифрование данных

В качестве библиотеки полностью гомоморфного шифрования выбрана TenSEAL, основанная на Microsoft SEAL, которая в настоящее время является наиболее используемой библиотекой полностью гомоморфного шифрования. С помощью API она обеспечивает простоту использования языка Python, при этом сохраняя эффективность за счет реализации большинства операций с использованием C++.

TenSEAL, основанная на Microsoft SEAL, в настоящее время является наиболее используемой библиотекой полностью гомоморфного шифрования. Например, данная библиотека использовалась в работах [3, 13, 15]. С помощью API она обеспечивает простоту использования языка Python, при этом сохраняя эффективность за счет реализации большинства операций с использованием C++.

TenSEAL позволяет производить поэлементное сложение, вычитание и умножение зашифрованных векторов, а шифрование и дешифрование данных осуществляет по схеме BFV для целых чисел или CKKS для вещественных чисел, которая и используется в разрабатываемой модели, так использование вещественных чисел позволяет добиться большей точности.

Для указания схемы и параметров шифрования в TenSEAL используется специальный объект – TenSEALContext.

Параметры шифрования θ схемы CKKS включают в себя:

- степень полиномиального модуля N ;
- размеры модуля коэффициента q .

Прежде чем приступить к определению параметрам шифрования, следует определить количество необходимых операций умножения:

- для операции скалярного произведения – 1;
- для аппроксимации сигмоидной функции – 2;
- для осуществления обратного распространения ошибки – 3.

Таким образом, мультипликативная глубина равна $1 + 2 + 3 = 6$, что определяет количество чисел, составляющих модуль коэффициента.

Степень полиномиального модуля, которую ещё называют коэффициентом масштабирования, должна быть степенью двойки, так как она определяет точность кодирования для двоичного представления числа. Также эта степень напрямую влияет на количество коэффициентов в полиноме открытого текста, размер элементов зашифрованного текста, вычислительную производительность схемы и уровень безопасности. При этом, чем выше степень полиномиального модуля, тем ниже производительность, но выше уровень безопасности.

Приняв желаемый уровень защищенности, эквивалентный AES, равный 128 битам, степень полиномиального модуля следует определить не ниже 8192, что позволит группировать до 4096 значений в одном зашифрованном тексте.

Размеры модуля коэффициента представляют собой список двоичных размеров, используя который TenSEAL генерирует список простых чисел этих двоичных размеров. Модуль коэффициента влияет на размер элементов зашифрованного текста, а длина списка указывает уровень схемы, то есть количество поддерживаемых умножений. При этом, чем длиннее данный список, тем выше уровень безопасности.

Так как желаемый уровень защищённости составляет 128 бит, количество умножений равно 6, а $128 / 6 = 21.3$, то в качестве двоичного размера следует использовать 21 бит. При этом двоичные размеры в количестве, равном количеству умножений, определяются в списке размеров со второй по предпоследнюю позицию, в то время как первый и последний размер в данном списке должны быть больше их по размеру.

Поэтому размеры модуля коэффициента [40, 21, 21, 21, 21, 21, 21, 40] обозначают то, что модуль коэффициента будет содержать 8 простых чисел: первое и последнее по 40 бит и остальные по 21 бит.

Таким образом, выбранные параметры шифрования схемы SKKS приведены в таблице 2.

Таблица 2 – Выбранные параметры шифрования схемы CKKS

Степень полиномиального модуля	Размеры модуля коэффициента
8192	[40, 21, 21, 21, 21, 21, 21, 40]

Для обеспечения безопасности данных на сервер нужно загружать уже зашифрованные на клиенте данные, для чего для каждой из выборок создадим зашифрованные вектора, которые сериализуем, то есть представим в виде двоичных данных, и запишем в файлы с расширением «hex». Каждый из таких файлов соответствует одному зашифрованному вектору и весит 429 Кбайт, поэтому для экономии получившиеся файлы архивируются.

Таким же образом сериализуем объект `TenSEALContext` для того, чтобы развернуть его на сервере и не настраивать параметры шифрования ещё раз.

2.3 Разработка модели логистической регрессии, обучаемой на зашифрованных данных

Перед тем, как приступить к обучению модели на сервере, следует загрузить и восстановить на нём сериализованный `TenSEALContext`, содержащий схему и параметры шифрования, настроенные на клиенте, а также сериализованные зашифрованные векторы.

Для восстановления `TenSEALContext` можно воспользоваться функцией `context_from()`, но для зашифрованных векторов следует сначала распаковать архив, а затем последовательно открыть каждый из двоичных файлов, из которого уже восстанавливается зашифрованный вектор в виде объекта `CKKSVector`.

Как уже отмечалось ранее, модель логистической регрессии в качестве функции потерь использует бинарную потерю кросс-энтропии, однако для борьбы с переобучением модели следует использовать регуляризацию, которая действует путем добавления штрафа к функции потерь, величина которого меняется в зависимости от типа регуляризации.

Так как для принятия решения о выдаче кредита следует учитывать все признаки, то следует использовать L2 регуляризацию, которая не обнуляет коэффициенты, а лишь уменьшает их величину.

Тогда функция потерь (4) примет вид:

$$L = \frac{1}{m} \cdot \sum_{i=1}^m [y^{(i)} \cdot \log(\hat{y}^{(i)}) + (1 - y^{(i)}) \cdot \log(1 - \hat{y}^{(i)})] + \frac{\lambda}{2 \cdot m} \cdot \sum_{j=1}^n \theta_j^2 \quad (5)$$

где λ – параметр регуляризации, который контролирует степень влияния штрафа на функцию потерь;

θ – вектор параметров модели.

Для обновления параметров применяется следующее правило:

$$\theta_j = \theta_j - \alpha \cdot \left[\frac{1}{m} \cdot \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) \cdot x^{(i)} + \frac{\lambda}{m} \cdot \theta_j \right] \quad (6)$$

Однако, учитывая ограничения полностью гомоморфного шифрования, примем $\alpha = 1$ и $\frac{\lambda}{m} = 0.05$, и тогда правило обновление параметров примет следующий вид:

$$\theta_j = \theta_j - \left[\frac{1}{m} \cdot \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) \cdot x^{(i)} + 0.05 \cdot \theta_j \right] \quad (7)$$

Поскольку полностью гомоморфное шифрование не позволяет напрямую вычислить сигмоидную функцию, так как её невозможно представить с помощью сложения и умножения, то её необходимо аппроксимировать с помощью полинома низкой степени. В результате проведённого анализа источников и литературы по теме исследования, в качестве аппроксимирующей функции была выбрана следующая функция:

$$\sigma(x) = -0.004 \cdot x^3 + 0.197 \cdot x + 0.5 \quad (8)$$

Данная функция была получена с помощью минимаксной аппроксимации, и она аппроксимирует сигмоидную функцию на отрезке $[-5; 5]$, поэтому на этапе подготовки данные были нормализованы в соответствии с данным диапазоном.

Используя PyTorch, создадим модель логистической регрессии, использующей зашифрованные данные, которая учитывает обновление параметров в соответствии с L2 регуляризацией, вычисляя вес с учётом принятого коэффициента, равного 0.05, а также переопределяет сигмоидальную функцию как полином с коэффициентами 0.5, 0.197, 0 и - 0.004.

3.5 Анализ результатов

Основные результаты, полученные в ходе эксперимента по обеспечению безопасности данных при обучении модели логистической регрессии на сервере, приведены в таблице 3.

Таблица 3 – Характеристика модели логистической регрессии для решения задачи кредитного скоринга

Параметр	Значение
Вес исходного файла с набором данных (csv)	30 407 Кбайт
Вес одного зашифрованного вектора (hex)	429 Кбайт
Время шифрования одного тензора ([3523, 19])	59 секунд
Точность обучения модели на зашифрованных данных	86.27 %
Точность обучения модели на незашифрованных данных	86.27 %
Среднее время обучения модели на зашифрованных данных	346 секунд

Вес одного зашифрованного вектора составляет 429 Кбайт, в то время как файл, содержащий набор из 20000 строк, весит всего 30 407 Кбайт, что свидетельствует о значительном увеличении объема данных после шифрования, что может оказывать влияние на требования к хранению и передаче данных. Также время шифрования одного тензора, составляющее 59 секунд, демонстрирует то, что процесс шифрования может быть достаточно времязатратным, что необходимо учитывать при планировании операций обработки больших данных.

При этом точность модели логистической регрессии, обученной на зашифрованных данных, составила 86%, что совпадает с точностью модели, обученной на незашифрованных данных. Этот результат подтверждает эффективность применения технологии полностью гомоморфного шифрования для защиты конфиденциальности данных в процессе их обработки, без потери качества моделирования.

Однако среднее время обучения модели на зашифрованных данных составляет 346 секунд, что указывает на то, что обучение на зашифрованных данных занимает больше времени по сравнению с обучением на незашифрованных данных. Однако с точки зрения обеспечения конфиденциальности и безопасности данных, затраты времени могут считаться оправданными.

Заключение

В данной работе рассматривалась проблема обеспечения безопасности данных, используемых банком для машинного обучения, так как утечка или раскрытие данных могут привести к репутационным потерям и штрафам за нарушение правил информационной безопасности.

В рамках проведенного исследования было осуществлено решение задачи кредитного скоринга путём разработки модели логистической регрессии, обучаемой на данных, зашифрованных с использованием технологии полностью гомоморфного шифрования. Для этого были проанализированы источники и литература по применению полностью гомоморфного шифрования для машинного обучения, в результате которого было установлено, что наиболее подходящей для машинного обучения библиотекой полностью гомоморфного шифрования является TenSEAL, а большинство работ посвящены решению задачи аппроксимации сигмоидной функции, поскольку полностью гомоморфное шифрование не позволяет вычислять напрямую функции, которые невозможно представить с помощью сложения и умножения. Также во всех рассмотренных работах процесс

шифрования данных не выделяется на отдельный этап, то есть в рамках клиент-серверной архитектуры загрузка и шифрование данных происходит на сервере, а не на клиенте, что также было решено в данной работе путём разработки дополнительных функций для библиотеки TenSEAL.

Применение полностью гомоморфного шифрования было продемонстрировано на примере решения задачи кредитного скоринга, которая является классической задачей для банка, а качестве модели была выбрана логистическая регрессия, рассматриваемая как простая однослойная нейронная сеть.

В качестве схемы шифрования была использована схема CKKS, так как она позволяет работать с вещественными числами, с помощью которой данные были зашифрованы на клиенте и переданы на сервер для обучения на них модели.

В результате обучения модели логистической регрессии на зашифрованных данных была достигнута точность 86.27 %, что совпало с точностью модели логистической регрессии, обученной на незашифрованных данных, и что демонстрирует применимость технологии полностью гомоморфного шифрования для обеспечения безопасности данных в машинном обучении, так как оно не влияет на качество прогноза, но при этом обеспечивает максимальный уровень защиты данных, так как их содержимое никогда не раскрывается перед сервером.

Тем не менее, необходимо отметить, что использование полностью гомоморфного шифрования влечёт за собой дополнительные вычислительные затраты, например, увеличение размера данных и времени обучения модели.

Направления для дальнейшего исследования могут включать в себя оптимизацию процесса отправки данных на сервер и получения данных с него, так как сейчас это выполняется вручную. Кроме того, в данной работе сейчас происходит расшифровка и новое шифрование весов после каждой эпохи, что необходимо из-за ограниченного количества операций умножений. Однако данный процесс можно оптимизировать путём отправки весов обратно на

клиент для расшифровки и повторного шифрования. В этом случае это приведет к передаче всего нескольких килобайт в эпоху.

Список литературы:

1. Варновский, Н. П., Шокуров, А. В. Гомоморфное шифрование. – Труды ИСП РАН. 2007.
2. Маршалко Г. Б., Труфанова Ю. А., Полиномиальные аппроксимации некоторых функций активации нейронных сетей, Информатика и автоматизация, 2022, выпуск 21, том 1, 161–180.
3. Barni M., Orlandi C., Piva A. A privacy-preserving protocol for neural-network-based computation. – 8th Workshop on Multimedia and Security, 2006. – P. 146–151.
4. Bourse F., Sanders O., Traoré J. Improved Secure Integer Comparison via Homomorphic Encryption. In Topics in Cryptology. – The Cryptographers’ Track at the RSA Conference 2020, Lecture Notes in Computer Science, Volume 12006. – P. 391–416.
5. Chabanne H., Wargny A., Milgram J., Morel C., Prouff E. Privacy-preserving classification on deep neural network. – IACR Cryptol. ePrint Arch, 2017. – P. 1–35.
6. Chen H, Gilad-Bachrach R., Han K., Huang Z., Jalali A., Laine K., Lauter K. Logistic regression over encrypted data from fully homomorphic encryption. – BMC Medical Genomics, Volume 11, Article number 81. – P. 56–67.
7. Crawford J. L. H., Gentry C., Halevi S., Platt D., Shoup V. Doing real work with FHE: The case of logistic regression. – Proc. 6th Workshop Encrypted Comput. Appl. Homomorphic Cryptogr, 2018. – 1–12.
8. Gilad-Bachrach R., Dowlin N., Laine K., Lauter E. K., Naehrig M., Wernsing J. CryptoNets: Applying Neural Networks to Encrypted Data with High Throughput and Accuracy. – JMLR Workshop and Conference Proceedings, Volume 48. – P. 201–210.

9. Guerra-Manzanares A., L. Lopez J.L., Maniatakos M., Shamout F. Privacy-Preserving Machine Learning for Healthcare: Open Challenges and Future Perspectives. – First International Workshop, TML4H 2023, Virtual Event, 2023. – P. 25–40.

10. Hesamifard E., Takabi H., Ghasemi M. CryptoDL: Deep neural networks over encrypted data. [Электронный ресурс]. URL: <https://arxiv.org/abs/1711.05189> (дата обращения: 05.03.2024).

11. Ioffe S., Szegedy C., Batch normalization: Accelerating deep network training by reducing internal covariate shift [Электронный ресурс]. URL: <https://arxiv.org/abs/1502.03167> (дата обращения: 05.03.2024).

12. Kahya A. Machine Learning over Encrypted Data With Fully Homomorphic Encryption. – Master of Science, Middle East Technical University. 2022.

13. Liu J., Juuti M., Lu Y., Asokan N. Oblivious neural network predictions via minionn transformations. ACM SIGSAC Conference on Computer and Communications Security, October 30 – November 03, 2017. – P. 619–631.

14. Martins P., Sousa L., Mariano A. A survey on fully homomorphic encryption: An engineering perspective. – ACM Computing Surveys, Volume 50, Number 6, 2018. – P. 1–33.

15. Mohassel P., Zhang Y. Secureml: A system for scalable privacy-preserving machine learning. – IEEE Symposium on Security and Privacy, SP 2017, San Jose, CA, USA, May 22-26, 2017. – P. 19–38.

16. Nandakumar K., Ratha N., Pankanti S., Halevi S. Towards Deep Neural Network Training on Encrypted Data. – CVPR Workshops, 2019. – P. 40–48.

17. Riazi M. S., Weinert C., Tkachenko O., Songhori E. M., Schneider T., Koushanfar F. Chameleon: A hybrid secure computation framework for machine learning applications. – 13 ACM Asia Conference on Information, Computer and Communications Security, ACM, Jun 4–8, 2018.

18. Vaikuntanathan C. J. V., Chandrakasan A. GAZELLE: a low latency framework for secure neural network inference [Электронный ресурс]. URL:

<https://www.usenix.org/conference/usenixsecurity18/presentation/juvekar> (дата обращения: 05.03.2024).

19. Vizitiu A., Nita C. I., Puiu A., Suciu C., Itu L. M. Applying Deep Neural Networks over Homomorphic Encrypted Medical Data [Электронный ресурс]. URL: <https://doi.org/10.1155/2020/3910250> (дата обращения: 05.03.2024).

20. Xu R., Nathalie Baracaldo N., Joshi J. Privacy-Preserving Machine Learning: Methods, Challenges and Directions [Электронный ресурс]. URL: <https://arxiv.org/abs/2108.04417> (дата обращения: 05.03.2024).

Khaustova I.V.

Togliatti State University
(Togliatti, Russia)

Anikina O.V.

Togliatti State University
(Togliatti, Russia)

USING FULLY HOMOMORPHIC ENCRYPTION TO PROTECT DATA IN MACHINE LEARNING IN THE CLOUD

***Abstract:** the paper addresses the issue of insufficient protection of confidential data used by banks for machine learning in the cloud. To solve this issue, the use of fully homomorphic encryption in machine learning and the approximation of the sigmoid function were analyzed. The problem of credit scoring was solved with full data security, for which the TenSEAL library was used to encrypt the data on the client side using the CKKS scheme and upload it to the server. On the server, a logistic regression model was trained on the encrypted data, demonstrating the same accuracy as a model trained on unencrypted data.*

***Keywords:** fully homomorphic encryption, CKKS, logistic regression, polynomial approximation, confidential machine learning*